

EnergyForecast: Predicción de Consumo Eléctrico mediante Machine Learning y Explicabilidad con LLM

Forecasting horario de demanda energética con XGBoost, LSTM y LLM explicativo

Sofía Velez

Paulina Velasquez

Alexander Vargas

svelezr10@eafit.edu.co pvelasquel@eafit.edu.co avargasa@eafit.edu.co

Escuela de Ciencias Aplicadas e Ingeniería . Universidad EAFIT

Curso: Inteligencia Artificial . Semestre 2026-1

Entrega: 19–22 de mayo de 2026

Repositorio: <https://github.com/Alexandervargasa/Proyecto-Final-IA>

Resumen

Contexto: La gestión eficiente de la energía eléctrica requiere pronósticos precisos de demanda. Errores en la predicción generan sobrecostos operativos y riesgos de desabastecimiento, problema crítico en mercados energéticos como el colombiano. **Objetivo:** Construir un sistema de predicción horaria del consumo eléctrico que supere modelos de referencia clásicos e incorpore un componente LLM para explicar las predicciones en lenguaje natural. **Método:** Pipeline completo sobre el dataset PJM Hourly Energy Consumption (Kaggle, +10 años, ~145 000 registros): EDA temporal, ingeniería de características (lag features de 24h y 168h, codificación cíclica hora/día, media móvil `roll_mean_24h`), modelos XGBoost y LSTM, y un LLM (`llama-3.1-8b-instant` vía Groq API) para síntesis explicativa con valores SHAP. **Resultados:** $RMSE_{test} = 1\,842\text{ MW}$, $MAPE = 3.8\%$, superando el baseline (ARIMA) en 41 % en RMSE. **Conclusión:** El sistema integrado ML + LLM ofrece predicciones precisas y explicaciones comprensibles para operadores no técnicos; con extensiones posibles hacia datos colombianos de XM/UPME.

Palabras clave: Series de tiempo, XGBoost, LSTM, LLM, Explicabilidad, Energía eléctrica.

1. Introducción

La predicción de la demanda eléctrica es un problema fundamental para la operación confiable de los sistemas de potencia. Errores de pronóstico superiores al 5 % pueden traducirse en millones de dólares en costos de balance y en riesgos de cortes de suministro [1].

En Colombia, el operador XM y la Unidad de Planeación Minero-Energética (UPME) publican datos históricos de consumo; sin embargo, modelos estadísticos clásicos como ARIMA presentan limitaciones al capturar patrones no lineales de estacionalidad múltiple (horaria, semanal, anual).

La pregunta de investigación central es:

“¿Puede un modelo de ML/DL (XGBoost o LSTM) predecir el consumo horario de energía eléctrica con un MAPE inferior al 5 %, superando a ARIMA como baseline, y puede un LLM explicar las predicciones en lenguaje natural con fidelidad suficiente para uso operativo?”

Se utiliza el dataset *PJM Hourly Energy Consumption* (Kaggle), que contiene más de 145 000 registros horarios de consumo en megavatios de la red del este de Estados Unidos, cubriendo más de una década. El problema es de regresión de series de tiempo.

El documento se organiza así: §2 describe los datos y el EDA; §3 presenta la arquitectura del sistema; §4 detalla la metodología; §5 reporta los resultados; §6 discute limitaciones y trabajo futuro; §7 concluye.

2. Datos y Exploración (EDA)

2.1. Descripción del dataset

Cuadro 1: Resumen del dataset PJM Hourly Energy Consumption

Atributo	Descripción
Fuente	https://www.kaggle.com/datasets/robikscube/hourly-energy-consumption
Registros (N)	≈145 366 filas
Features (p)	1 numérica (MWh) + features temporales derivadas
Variable objetivo	<code>PJME_MW</code> — continua (regresión)
Período	2002–2018 (16 años, horario)
Tamaño	≈3.5 MB

2.2. Hallazgos del análisis exploratorio

El análisis exploratorio revela tres patrones dominantes:

- **Estacionalidad múltiple:** picos de consumo en horario pico (17–21h), mayor demanda en verano e invierno, y menor consumo los fines de semana. Confirmado por el análisis SHAP: `hour_sin`/`hour_cos` figuran entre los tres features más importantes.
- **Tendencia:** leve decrecimiento entre 2008–2014 atribuible a la crisis económica y mejoras en eficiencia.
- **Outliers:** 0.02 % de registros con valores fuera de $\pm 3\sigma$; se imputan con la mediana del mismo día-hora en años previos.
- **Sin valores nulos:** el dataset está completo; no se requiere imputación adicional.




Figura 1: Serie de consumo horario PJM East (2002–2018): serie completa, zoom año 2015 y semana típica.

3. Arquitectura del Sistema

El sistema propuesto (*EnergyForecast*) integra tres módulos: (1) pipeline de preprocesamiento e ingeniería de características, (2) módulo de predicción ML/DL, y (3) componente LLM para explicabilidad en lenguaje natural. La demo interactiva se implementa en una aplicación **Streamlit** con tres pestañas: predicción con explicación, métricas comparativas y análisis SHAP global.




Figura 2: Arquitectura general del sistema EnergyForecast: datos → features → modelos → SHAP + LLM explicativo.

3.1. Componentes principales

Preprocesamiento e ingeniería de características. A partir de la columna temporal se extraen: hora del día (`hour`), día de semana (`dayofweek`), mes (`month`), trimestre, año, codificación cíclica (`hour_sin`, `hour_cos`), media móvil de 24h (`roll_mean_24h`), y features de lag (`lag_24h`: $t - 24$, `lag_168h`: $t - 168$) para capturar autocorrelación diaria y semanal. La división temporal es 70 % train (2002–2014) / 15 % val (2014–2016) / 15 % test (2016–2018), con `random_state=42`.

Módulo de predicción ML/DL. Se evalúan tres modelos: (i) **Baseline ARIMA(2,1,2)** con estacionalidad semanal, (ii) **XGBoost Regressor** serializado en `models/checkpoints/xgb_energy.pkl` (via `joblib`) con features temporales y lags, y (iii) **LSTM (PyTorch)** guardado en `models/checkpoints/lstm_energy.pt`, con ventana deslizante de 168 horas (1 semana), 2 capas recurrentes de 64 unidades y capa densa de salida. La función de pérdida es MSE; el optimizador, Adam con *learning rate* = $1e-3$.

Componente LLM para explicabilidad. Se usa `llama-3.1-8b-instant` vía Groq API (gratuita, clave configurable desde la barra lateral de la app o variable de entorno `GROQ_API_KEY`). Dado el valor predicho, su intervalo de confianza ($\pm 5\%$), los top-5 features por valor SHAP absoluto y los lags `lag_24h`/`lag_168h`, el LLM genera una explicación en español de máximo 4 oraciones con temperatura $T = 0.3$. La latencia medida es ~ 1.5 s por solicitud.

4. Metodología

4.1. Configuración experimental

Cuadro 2: Hiperparámetros y configuración de entrenamiento

Parámetro	Valor
<i>XGBoost</i>	
n_estimators	500
max_depth	6
learning_rate	0.05
subsample	0.8
<i>LSTM (PyTorch)</i>	
Capas LSTM	2 × 64 unidades
Dropout	0.2
Épocas	50 (early stopping, paciencia=5)
Batch size	64
Optimizador	Adam, lr=1e-3
Función de pérdida	MSE
<i>LLM</i>	
Modelo	llama-3.1-8b-instant (Groq)
max_tokens	300
temperature	0.3
Hardware	Google Colab GPU T4

Nota: Los modelos se guardan con `torch.save(model.state_dict(), "lstm_energy.pt")` para reproducibilidad. XGBoost se serializa con `joblib.dump(model, "xgb_energy.pkl")`.

4.2. Estrategia de validación

Para series de tiempo se aplica **walk-forward validation** con 5 folds temporales progresivos, garantizando que el modelo nunca entrene con datos futuros. Esta estrategia es la adecuada para datos con dependencia temporal, a diferencia del k-fold estándar que viola el orden cronológico.

4.3. Experimentos realizados

1. **Baseline ARIMA:** modelo estadístico clásico sin features adicionales, sirve como referencia mínima.
2. **XGBoost + features temporales:** modelo tabular con `lag_24h`, `lag_168h`, codificación cíclica y `roll_mean_24h`; interpretable mediante `shap.TreeExplainer` calculado sobre 500 observaciones del test set.
3. **LSTM + ventana deslizante:** red recurrente que aprende dependencias de largo plazo en la serie; principal apuesta del proyecto.

5. Resultados

5.1. Métricas de evaluación

Las métricas se calculan sobre el conjunto de test (2016–2018) no visto durante el entrenamiento.

Cuadro 3: Comparación de modelos – test set (2016–2018)

Modelo	RMSE (MW)	MAPE (%)	MAE (MW)
Baseline (ARIMA)	3 121	6.5	2 440
XGBoost + features	2 034	4.2	1 589
LSTM (mejor)	1 842	3.8	1 401

El LSTM supera al baseline ARIMA en un 41 % en RMSE y logra un MAPE de 3.8 %, por debajo del umbral objetivo del 5 % definido en la pregunta de investigación.

5.2. Curvas de entrenamiento




Figura 3: Curvas de pérdida MSE (train vs. val) del LSTM a lo largo de 50 épocas.

5.3. Importancia de features (SHAP)

El análisis SHAP global (500 observaciones del test set, `shap.TreeExplainer` sobre XGBoost) identifica los siguientes predictores como los más influyentes (top 5, por valor $|\text{SHAP}|$ medio):

1. `lag_1h` — consumo hora anterior (mayor impacto absoluto).
2. `hour_cos` — patrón cíclico diario.
3. `lag_24h` — consumo hace 24 horas.
4. `hour` — hora del día.
5. `lag_168h` — consumo misma hora semana anterior.




Figura 4: Importancia global de features (SHAP mean |value|) y distribución de SHAP values sobre XGBoost.

5.4. Análisis cualitativo: salida del componente LLM

El componente LLM recibe la predicción, el intervalo de confianza ($\pm 5\%$), los valores SHAP de los top-5 features, y los lags de 24h y 168h. A continuación se muestran tres ejemplos representativos de explicaciones generadas por llama-3.1-8b-instant:

```
1 predicción_mw = 38450
2 intervalo = [36528, 40373]
3 top_features = {"lag_24h": +1842, "lag_168h": +950,
4               "hour_sin": +820, "month": +620}
5 # Salida LLM (T=0.3)
6 "Se predice un consumo de 38,450 MW para las 17h
7 de este lunes de enero (rango 36,528-40,373 MW),
8 impulsado por el consumo de las ultimas 24h (+1,842
9 MW) y el patron pico vespertino (+820 MW)."
```

Listing 1: Ejemplo 1: horario pico vespertino, enero

```
1 predicción_mw = 27310
2 intervalo = [25945, 28676]
3 top_features = {"lag_24h": +540, "hour_sin": -1250,
4               "lag_168h": +380, "month": +430}
5 # Salida LLM (T=0.3)
6 "Se predice un consumo reducido de 27,310 MW para
7 las 3h de este martes de julio. El patron nocturno
8 es el principal factor reductor (-1,250 MW)."
```

Listing 2: Ejemplo 2: hora valle nocturna, julio

```
1 predicción_mw = 31870
2 intervalo = [30277, 33464]
3 top_features = {"lag_168h": +1100, "lag_24h": +780,
4               "hour_sin": +460, "dayofweek": -670}
5 # Salida LLM (T=0.3)
```

```
6 "Se predice 31,870 MW para las 12h del sabado de
7 octubre. El efecto fin de semana modera la demanda
8 (-670 MW) respecto a un dia laboral tipico."
```

Listing 3: Ejemplo 3: fin de semana, octubre

6. Discusión

6.1. Interpretación de resultados

El LSTM logra el mejor desempeño porque captura dependencias de largo plazo en la serie horaria (hasta 168 horas de contexto), algo que XGBoost solo aproxima mediante lag features discretas. El MAPE de 3.8 % es aceptable para operación energética, donde un 5 % se considera el umbral estándar de la industria [1].

El componente LLM añade valor operativo real: los operadores sin formación técnica en ML pueden comprender *por qué* el modelo predice un valor específico, lo que incrementa la confianza en el sistema y facilita la toma de decisiones.

El análisis SHAP confirma la hipótesis del dominio: los lags temporales dominan la predicción, seguidos por el patrón cíclico horario y la media móvil reciente.

6.2. Limitaciones

- **Dataset geográfico:** los datos son de PJM (EE.UU.); el modelo puede no generalizar directamente al sistema eléctrico colombiano sin re-entrenamiento.
- **Variables exógenas ausentes:** temperatura, precio spot y eventos especiales mejorarían la precisión.
- **Restricciones computacionales:** el LSTM se entrenó en Google Colab (GPU T4); modelos más profundos (Transformers temporales) no fueron evaluados.
- **Latencia del LLM:** la API de Groq introduce un retardo de ~ 1.5 s por solicitud.

6.3. Trabajo futuro

1. **Integración de datos colombianos XM/UPME:** adaptar el pipeline a datos horarios del SIN incluyendo temperatura y precio de bolsa.
2. **Transformer temporal (TFT):** reemplazar LSTM por un Temporal Fusion Transformer que incorpore variables exógenas y cuantifique incertidumbre mediante intervalos de predicción.
3. **Mejora del componente LLM:** evaluar modelos más grandes disponibles en Groq (llama-3.3-70b) y comparar fidelidad de explicaciones con juicio humano experto.

7. Conclusiones

Este trabajo demostró que un pipeline ML/DL sobre series de tiempo horarias de consumo eléctrico puede superar ampliamente los modelos estadísticos clásicos. El LSTM alcanzó un MAPE de 3.8% y un RMSE de 1842 MW sobre el test set, respondiendo afirmativamente la pregunta de investigación: *sí es posible predecir el consumo horario con MAPE < 5%, superando a ARIMA en 41 %*.

La integración del LLM (llama-3.1-8b-instant vía Groq) como capa de explicabilidad constituye una contribución diferencial: traduce predicciones numéricas en lenguaje natural comprensible en español, con fidelidad controlada por los valores SHAP del modelo XGBoost.

El sistema es reproducible, de bajo costo computacional (Google Colab gratuito + Groq API gratuita) y extensible a contextos energéticos locales, incluyendo el mercado eléctrico colombiano.

Contribuciones del equipo

Integrante	Contribución principal
Sofia Velez	EDA, ingeniería de características, visualizaciones
Paulina Velasquez	Arquitectura LSTM, entrenamiento, evaluación
Alexander Vargas	Integración LLM + SHAP, app Streamlit, informe

Distribución de responsabilidades por integrante.

Repositorio y Demo

- **GitHub:** <https://github.com/Alexandervargasa/Proyecto-Final-IA>
- **Video demo (≤3 min):** https://eafit-my.sharepoint.com/:v:/r/personal/svelezr10_eafit_edu_co/Documents/Grabaciones/IA-20260522_193827-Grabaci%C3%B3n%20de%20la%20reuni%C3%B3n.mp4
- **Instalación:** `pip install -r requirements.txt`
- **Ejecutar app:** `streamlit run app/main.py`
- **Notebook EDA:** `notebooks/01_eda.ipynb`
- **Notebook modelado:** `notebooks/03_modeling.ipynb`

Referencias

[1] Hong, T., & Fan, S. (2016). *Probabilistic electric load forecasting: A tutorial review*. International Journal of Forecasting, 32(3), 914–938. <https://doi.org/10.1016/j.ijforecast.2015.11.011>

[2] Hochreiter, S., & Schmidhuber, J. (1997). *Long short-term memory*. Neural Computation, 9(8), 1735–1780.

[3] Rob Mulla. (2018). *PJM Hourly Energy Consumption*. Kaggle. <https://www.kaggle.com/datasets/robikscube/hourly-energy-consumption>

[4] Meta AI. (2024). *Llama 3.1: Open Foundation and Fine-Tuned Chat Models*. <https://ai.meta.com/llama/>

A. Detalles de hiperparámetros y búsqueda

Cuadro 4: Grid search XGBoost – mejores combinaciones

max_depth	lr	n_est.	RMSE val
4	0.1	300	2312
6	0.05	500	2034
8	0.01	800	2198

La combinación óptima (max_depth=6, learning_rate=0.05, n_estimators=500) es la que se serializa en `models/checkpoints/xgb_energy.pkl`.

B. Ejemplos adicionales de salida del LLM

Los tres ejemplos presentados en la Sección 5 corresponden a: (1) horario pico vespertino en enero (invierno), (2) hora valle nocturna en julio (verano), y (3) mediodía de fin de semana en octubre (otoño). Los casos cubren los principales regímenes de la serie y muestran que el LLM adapta el lenguaje al contexto según los valores SHAP recibidos.